APLICAÇÃO DO ALGORITMO DOUBLE K-MEANS NA BASE DE DADOS SPAMBASE

BRUNO HENRIQUE SANTOS DE ALMEIDA
PAMELLA VITORIA GOMES FARIAS
ROZYELAYNY NASCIMENTO

Universidade Federal de Pernambuco
Programa de Pós Graduação em Ciência da Computação

Resumo. O presente artigo aplica o método de agrupamento Double K-Means na base de dados Spambase, com o objetivo de identificar padrões e características que diferenciam e-mails legítimos de mensagens de spam.

1. Introdução

2. Algoritmo Double K-Means

3. Base de Dados

A base *Spambase*, do repositório UCI (⟨https://archive.ics.uci.edu/dataset/94/spambase⟩), foi criada em 1999 nos laboratórios da Hewlett-Packard (HP Labs) a partir de e-mails reais. Os spams vieram de denúncias de usuários e os e-mails legítimos vieram de mensagens pessoais e de trabalho dos funcionários. Ela tem **4601 e-mails**, cada um descrito por **57 atributos numéricos contínuos** e por uma classe binária, `is_spam`. Não há valores ausentes.

Atributos. Os atributos são frequências calculadas sobre o texto de cada e-mail e formam três grupos (Tabela 1).

Key words and phrases. Agrupamento, K-Means, Spambase, Spam, Double K-Means.

Tabela 1. Grupos de atributos da Spambase.

Grupo	Qtd.	Descrição
`word_freq_`*PALAVRA*	48	Percentual (0–100) das palavras do e-mail iguais a *PALAVRA* (ex.: `make`, `free`, `money`, `hp`, `george`, `edu`).
`char_freq_`*CARACTERE*	6	Percentual (0–100) dos caracteres iguais a `;` `(` `[` `!` `$` `#`.
`capital_run_length_*`	3	Média (`average`), maior (`longest`) e soma (`total`) dos comprimentos das sequências contínuas de letras maiúsculas.
`is_spam` (classe)	1	1 = spam, 0 = não-spam.

Distribuição das classes. A base é moderadamente desbalanceada: são **1813 spams (39,4%)** e **2788 e-mails legítimos (60,6%)**. Por isso todas as divisões em treino e teste da Questão 2 usam amostragem estratificada, que preserva essas proporções.

Características relevantes.

- **Esparsidade:** 77,4% dos valores da matriz de dados são zero, já que cada e-mail usa poucas das 48 palavras monitoradas. Das 57 variáveis, 46 têm mais de 70% de zeros e 19 têm mais de 90%.
- **Escalas muito diferentes:** as frequências ficam entre 0 e 100 (na maioria das vezes abaixo de 1), enquanto os atributos de maiúsculas chegam a milhares. Por exemplo, `capital_run_length_total` tem mediana 95 e máximo 15 841.
- **Forte assimetria:** as distribuições têm cauda longa à direita (assimetria mediana de 9,7 entre as variáveis, chegando a 31) e muitos valores discrepantes.
- **Registros repetidos:** há 391 linhas duplicadas, mantidas como na base original.

A Tabela 2 mostra que alguns atributos separam bem as classes. Palavras e símbolos comerciais (`remove`, `free`, `your`, `!`, `$`) e o uso de maiúsculas são muito mais frequentes nos spams. Já `hp`, `george` e `edu` aparecem quase só nos e-mails legítimos, pois refletem o ambiente da HP Labs (George Forman é um dos autores da base). Essa origem explica o pequeno grupo de e-mails internos encontrado pelo double k-means na Questão 1.

Tabela 2. Média de atributos selecionados por classe.

Atributo	Não-spam	Spam
word_freq_remove	0,009	0,275
word_freq_free	0,074	0,518
word_freq_your	0,439	1,380
char_freq_!	0,110	0,514
char_freq_$	0,012	0,174
capital_run_length_total	161,47	470,62
word_freq_hp	0,895	0,017
word_freq_george	1,265	0,002
word_freq_edu	0,287	0,015

Pré-processamento. Por causa das escalas tão diferentes, todos os atributos foram padronizados (*z-score*: média zero e desvio-padrão um). Na Questão 1, que é não supervisionada, a padronização usa a base inteira. Na Questão 2, a média e o desvio são estimados apenas no conjunto de treinamento de cada fold e depois aplicados ao teste, para não vazar informação do teste para o modelo. Nenhum atributo ou registro foi removido.

4. Questões

4.1. **Questão 1:**

Organização do experimento. Os 57 atributos foram padronizados (*z-score*) sobre toda a base, pois têm escalas muito diferentes (os atributos `capital_run_length_*` chegam a milhares, enquanto as frequências de palavras ficam entre 0 e 100). O double k-means minimiza

$$W(G,U,V)=\sum_{k=1}^{K}\sum_{h=1}^{H}\sum_{i=1}^{N}\sum_{j=1}^{P}u_{ik}\,v_{jh}\,(x_{ij}-g_{kh})^2$$

alternando três passos: (1) cálculo dos protótipos ótimos $g_{kh}=\frac{1}{n_k n_h}\sum_{i\in P_k}\sum_{j\in Q_h}x_{ij}$, com U e V fixos; (2) realocação dos objetos, com G e V fixos; e (3) realocação das variáveis, com G e U fixos. Os passos se repetem enquanto houver transferência de objetos ou de variáveis. Se um grupo fica vazio, ele recebe o elemento mais distante do protótipo do próprio grupo.

Para cada $K\in\{2,3,4\}$ e $H\in\{1,\dots,K\}$ (9 pares), o algoritmo foi executado **100 vezes** a partir de partições iniciais aleatórias, e foi mantida a execução de menor W. As 100 execuções de cada par rodaram em paralelo em uma GPU NVIDIA A100 (PyTorch), cerca de 1 s por par. Todas convergiram. Para a melhor solução de cada par calculou-se a silhueta da partição dos objetos (distância euclidiana nos dados padronizados).

Silhueta e escolha de K^*. A Tabela 3 e a Figura 1 mostram os resultados. A silhueta é máxima no par $(K, H) = (2, 2)$, com valor 0,660, bem acima dos demais (todos $\leq 0{,}30$). Portanto,

$$K^* = \arg\max_{(K,H)} \mathrm{Sil}(K, H) = 2.$$

Tabela 3. Melhor solução (menor W em 100 execuções) de cada par (K, H).

K	H	W (melhor)	Iterações	Tamanho dos grupos	Silhueta
2	1	256 513,75	11	[3583, 1018]	0,2961
2	2	244 486,70	40	[4567, 34]	**0,6596**
3	1	254 414,01	40	[1187, 3382, 32]	0,2515
3	2	239 373,66	60	[34, 3470, 1097]	0,2454
3	3	234 585,87	34	[34, 3373, 1194]	0,1409
4	1	253 278,68	38	[2242, 22, 697, 1640]	0,0484
4	2	233 358,70	35	[3275, 1049, 253, 24]	0,2428
4	3	228 516,44	45	[24, 3256, 1080, 241]	0,1620
4	4	227 086,08	49	[26, 1039, 3249, 287]	0,1697

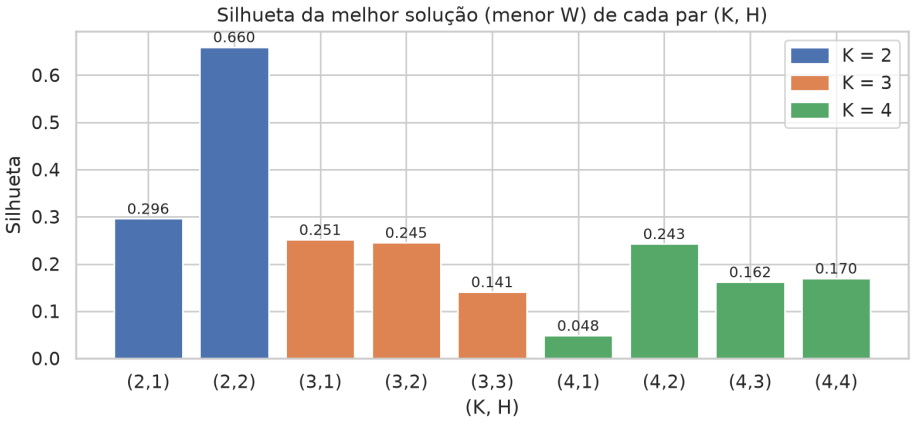


Figura 1. Silhueta $\times$ (K, H) para a melhor solução de cada par.

Índice de Rand corrigido. Comparando a partição em $K^* = 2$ grupos com a classe a priori (spam / não-spam), obtém-se **ARI** $= -0{,}0049$. O valor é praticamente zero, ou seja, a concordância é a esperada ao acaso: a partição encontrada não tem relação com a classe spam.

(i) Matriz de protótipos dos blocos G. A melhor solução com $K^* = 2$ $(H = 2)$ separa as variáveis em dois grupos. Q_2 tem 11 variáveis: `hp`, `hpl`, `650`, `lab`, `labs`,

`telnet`, `857`, `415`, `85`, `technology` e `direct`. Q_1 reúne as outras 46. A Tabela 4 e a Figura 2 mostram os protótipos.

Tabela 4. Matriz de protótipos G (dados padronizados), $K^* = 2$, $H = 2$.

	Q_1 (46 variáveis)	Q_2 (11 variáveis)
P_1 ($n = 4567$)	0,0011	−0,0511
P_2 ($n = 34$)	−0,1444	6,8612

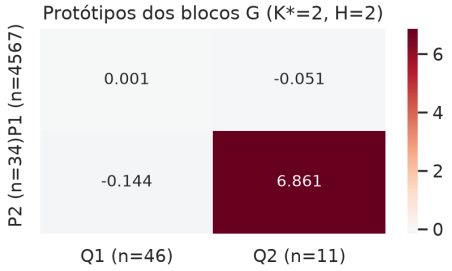


Figura 2. Protótipos dos blocos G.

O bloco (P_2, Q_2) tem protótipo de 6,86 desvios-padrão, enquanto os outros ficam próximos de zero. O grupo P_2 é formado por 34 e-mails que usam com frequência muito alta as palavras de Q_2, típicas de mensagens internas do laboratório (HP Labs) onde a base foi coletada.

Tabela 5. Partição do double k-means ($K^* = 2$) × classe a priori.

Cluster	Não-spam	Spam	Total
P_1	2754	1813	4567
P_2	34	0	34
Total	2788	1813	4601

(ii) Matriz de confusão. Os 34 e-mails de P_2 são todos legítimos, e P_1 reúne todos os 1813 spams junto com 2754 não-spams (Tabela 5 e Figura 3).

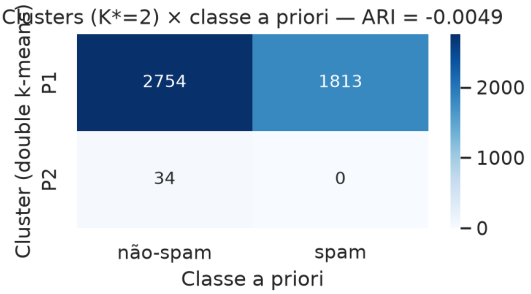


Figura 3. Matriz de confusão: clusters × classe a priori.

(iii) Função objetivo × iterações. A Figura 4 mostra a função objetivo da melhor execução com $K^* = 2$. Ela decresce de forma monótona, de 262 253,78 na solução inicial para 244 486,70, e o algoritmo para na iteração 40, quando não há mais transferências.

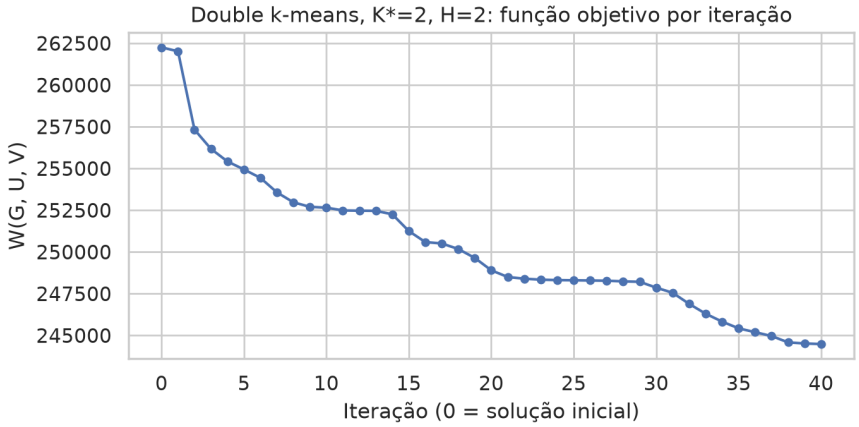


Figura 4. Função objetivo W por iteração (melhor execução, $K^* = 2$, $H = 2$).

Comentário. A silhueta escolhe $K^* = 2$ porque o par $(2, 2)$ isola um grupo pequeno, extremo e bem separado dos demais. Essa estrutura é real nos dados, mas não corresponde à divisão spam × não-spam, como mostram o ARI próximo de zero e a matriz de confusão. O resultado reflete limitações do double k-means: sensibilidade a valores discrepantes e preferência por grupos compactos e esféricos, numa base esparsa (a maioria dos atributos tem mais de 70% de zeros) e muito assimétrica. Também mostra que um índice interno alto (silhueta) não garante concordância com as classes conhecidas (validação externa).

4.2. **Questão 2:**

Versões da base.

- **V1 (original):** classe `is_spam`, 2 classes a priori (2788 não-spam e 1813 spam);
- **V2 (clusters):** classe igual ao grupo do double k-means com $K^* = 2$ (Questão 1), com 4567 e 34 exemplos.

Classificadores. Em todos os classificadores bayesianos, x_k é atribuído à classe de maior posteriori $P(\omega_i \mid x_k) = p(x_k \mid \omega_i)P(\omega_i)/\sum_r p(x_k \mid \omega_r)P(\omega_r)$, com $P(\omega_i) = n_i/n$ (máxima verossimilhança).

(i) **Bayesiano gaussiano:** $p(x_k \mid \omega_i)$ normal multivariada com $\hat{\mu}_i$ e $\hat{\Sigma}_i$ de máxima verossimilhança. Como alguns atributos são quase constantes dentro de uma classe, somou-se $10^{-3}I$ a $\hat{\Sigma}_i$ para que ela seja inversível.

(ii) **Bayesiano k-vizinhos:** $P(\omega_i \mid x) = k_i/k$, em que k_i é o número de vizinhos da classe ω_i entre os k mais próximos. Hiper-parâmetros: distância (Euclidiana, City-Block ou Chebyshev) e $k \in \{1, 3, \ldots, 31\}$.

(iii) **Bayesiano janela de Parzen:** kernel multivariado produto de gaussianas univariadas, $p(x \mid \omega_i) = \frac{1}{n_i}\sum_{l\in\omega_i}\prod_{j=1}^{d}\frac{1}{h}\varphi\Big(\frac{x_j - x_{lj}}{h}\Big)$. Hiper-parâmetro: h, em 24 valores log-espaçados entre 0,1 e 20.

(iv) **Regressão logística:** multinomial com regularização L2. Hiper-parâmetro: $C \in \{10^{-3}, 10^{-2}, \ldots, 10^{4}\}$.

(v) **Voto majoritário:** combina as predições de (i)–(iv). Em caso de empate, vence a classe de maior posteriori média.

Organização dos experimentos.

- **Validação cruzada estratificada 30×10-folds:** em cada uma das 30 repetições (sementes diferentes), a base é dividida em 10 folds estratificados. Cada fold é usado uma vez como teste, e os outros 9 formam o conjunto de aprendizagem. Isso dá 300 avaliações por classificador e por versão. As partições são as mesmas para os 5 classificadores, o que torna a comparação pareada.
- **Ajuste de hiper-parâmetros:** dentro dos 9 folds de aprendizagem faz-se uma validação cruzada estratificada 5-folds. Escolhe-se a combinação de maior F-measure média nos 5 folds internos, retreina-se o modelo nos 9 folds com esses valores e avalia-se no fold de teste, que nunca participa do ajuste.
- **Padronização:** o *z-score* é estimado só nos dados de treinamento de cada etapa, para que nenhuma informação do teste seja usada.
- **Métricas:** taxa de erro, precisão, cobertura e F-measure. Na V1 a classe positiva é spam; na V2 usa-se a média *macro* entre as classes.

Hiper-parâmetros selecionados. A Tabela 6 mostra os valores mais escolhidos nos 300 folds externos. A Figura 5 mostra a F-measure média da validação interna para cada valor.

Tabela 6. Hiper-parâmetros mais selecionados (número de folds externos, em 300).

Classificador	V1 (original)	V2 (clusters)
k-NN	City-Block, $k = 1$ (99); City-Block, $k = 5$ (94); Euclidiana, $k = 1$ (54)	Euclidiana, $k = 1$ (184); City-Block, $k = 1$ (36)
Parzen	$h = 0{,}50$ (245); $h = 0{,}63$ (49)	$h = 0{,}10$ (124); $h = 1{,}00$ (49)
Reg. logística	$C = 10$ (122); $C = 100$ (95)	$C = 0{,}1$ (176); $C = 1$ (120)

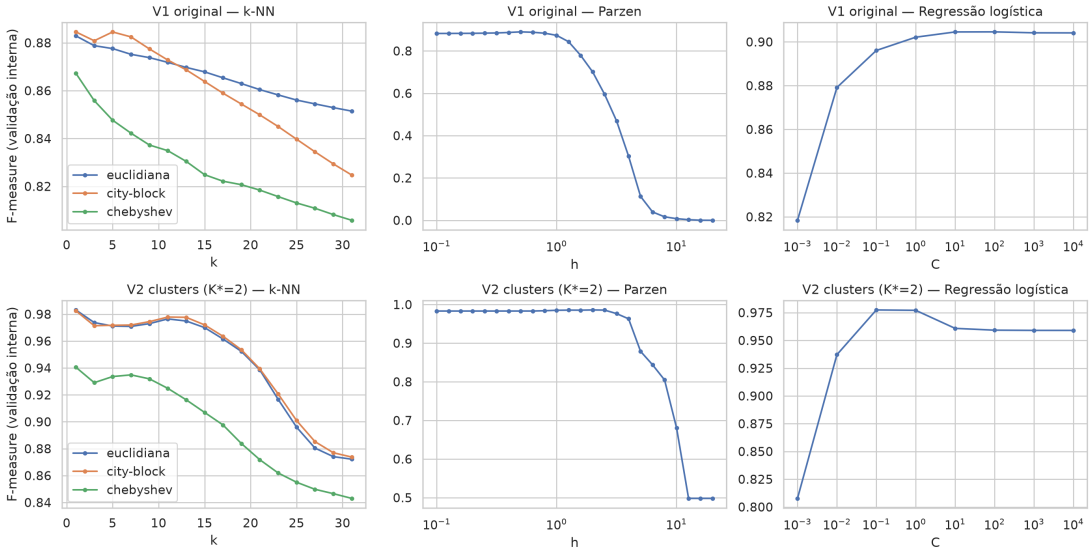


Figura 5. F-measure média da validação interna (5-folds) em função de cada hiper-parâmetro.

(b) Estimativas pontuais e intervalos de confiança. Para cada classificador e métrica, a média dos 10 folds de cada repetição dá 30 valores. A estimativa pontual é a média desses 30 valores, e o intervalo de confiança de 95% é $\bar{m} \pm t_{0{,}975;29}\, s/\sqrt{30}$. Usam-se as médias por repetição porque os folds de uma mesma repetição compartilham dados de treino e não são independentes. Os resultados estão nas Tabelas 7 e 8 e na Figura 6.

Tabela 7. V1 (original): média e IC 95%.

Classificador	Taxa de erro	Precisão	Cobertura	F-measure
Gaussiano	0,1767 [0,1763; 0,1770]	0,7052 [0,7048; 0,7057]	**0,9499** [0,9494; 0,9504]	0,8092 [0,8089; 0,8096]
k-NN	0,0861 [0,0851; 0,0871]	0,9121 [0,9101; 0,9141]	0,8658 [0,8632; 0,8684]	0,8878 [0,8864; 0,8892]
Parzen	0,0792 [0,0786; 0,0798]	0,9138 [0,9129; 0,9147]	0,8826 [0,8812; 0,8840]	0,8977 [0,8969; 0,8985]
Reg. logística	0,0732 [0,0728; 0,0735]	**0,9229** [0,9221; 0,9237]	0,8891 [0,8883; 0,8899]	0,9054 [0,9049; 0,9059]
Voto majoritário	**0,0655** [0,0648; 0,0661]	0,9184 [0,9172; 0,9195]	0,9157 [0,9145; 0,9169]	**0,9168** [0,9160; 0,9176]

Tabela 8. V2 (clusters, $K^* = 2$): média e IC 95%.

Classificador	Taxa de erro	Precisão	Cobertura	F-measure
Gaussiano	0,0459 [0,0457; 0,0462]	0,5561 [0,5550; 0,5571]	0,8524 [0,8471; 0,8577]	0,5866 [0,5850; 0,5882]
k-NN	0,0008 [0,0007; 0,0008]	**0,9812** [0,9785; 0,9838]	0,9720 [0,9695; 0,9746]	0,9726 [0,9709; 0,9743]
Parzen	0,0005 [0,0004; 0,0005]	0,9796 [0,9774; 0,9818]	0,9956 [0,9924; 0,9989]	0,9856 [0,9828; 0,9883]
Reg. logística	0,0007 [0,0006; 0,0008]	0,9680 [0,9646; 0,9714]	0,9955 [0,9922; 0,9988]	0,9789 [0,9759; 0,9818]
Voto majoritário	**0,0004** [0,0003; 0,0005]	0,9807 [0,9782; 0,9832]	**0,9973** [0,9945; 1,0000]	**0,9872** [0,9846; 0,9898]

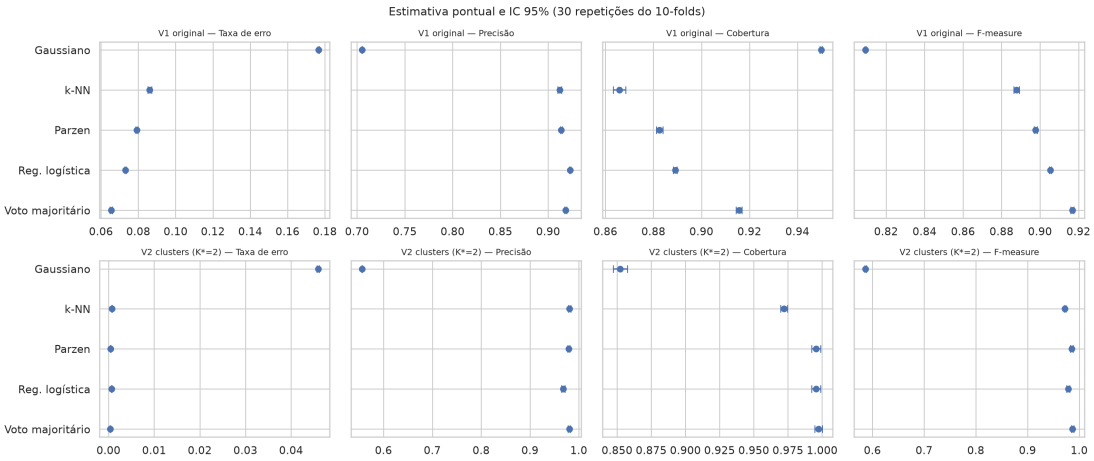


Figura 6. Estimativas pontuais e IC 95% (linha superior: V1; inferior: V2).

Na V1, o voto majoritário tem a menor taxa de erro (6,55%) e a maior F-measure (0,917), seguido pela regressão logística, Parzen e k-NN. O bayesiano gaussiano é o pior em erro (17,7%), mas tem a maior cobertura (0,950) com precisão baixa (0,705): ele classifica muitos e-mails legítimos como spam, porque a hipótese de normalidade é ruim para atributos esparsos e de cauda pesada. Na V2 a tarefa é muito mais fácil, porque as classes foram definidas pelo próprio agrupamento a partir de um grupo extremo em poucas variáveis. O erro fica abaixo de 0,1% para todos os classificadores, exceto o gaussiano (4,6%; F-measure 0,587): estimar uma matriz de covariância 57×57 com cerca de 31 exemplos de treino da classe minoritária é mal condicionado.

(c) Teste de Friedman e pós-teste de Nemenyi. Para cada versão e métrica, os blocos são as 30 repetições e os tratamentos são os 5 classificadores. O posto 1 indica o melhor classificador. A diferença crítica de Nemenyi ($\alpha = 0{,}05$, $k = 5$, $N = 30$) é $CD = q_\alpha \sqrt{k(k+1)/(6N)} = 1{,}114$.

Tabela 9. Teste de Friedman e postos médios (1 = melhor).

Base	Métrica	χ^2_F	p-valor	Gaussiano	k-NN	Parzen	Reg. log.	Voto
V1	Taxa de erro	120,00	$5{,}3 \times 10^{-25}$	5,00	4,00	3,00	2,00	1,00
	Precisão	108,51	$1{,}5 \times 10^{-22}$	5,00	3,57	3,33	1,10	2,00
	Cobertura	118,51	$1{,}1 \times 10^{-24}$	1,00	5,00	3,93	3,07	2,00
	F-measure	120,00	$5{,}3 \times 10^{-25}$	5,00	4,00	3,00	2,00	1,00
V2	Taxa de erro	97,10	$4{,}1 \times 10^{-20}$	5,00	3,40	1,90	3,12	1,58
	Precisão	94,04	$1{,}8 \times 10^{-19}$	5,00	2,75	1,92	3,65	1,68
	Cobertura	98,18	$2{,}4 \times 10^{-20}$	5,00	3,75	1,97	2,68	1,60
	F-measure	98,26	$2{,}3 \times 10^{-20}$	5,00	3,60	1,88	2,97	1,55

O teste de Friedman rejeita a hipótese de desempenhos equivalentes em todas as métricas e nas duas versões ($p < 10^{-18}$). Resultados do pós-teste de Nemenyi (Figuras 7 e 8):

- **V1, taxa de erro e F-measure:** a ordem voto < reg. logística < Parzen < k-NN < gaussiano é a mesma nas 30 repetições. Classificadores vizinhos nessa ordem não diferem significativamente (diferença de posto 1,0 < CD; $p = 0{,}10$). Pares a duas ou mais posições de distância diferem ($p < 0{,}001$): por exemplo, o voto supera Parzen, k-NN e gaussiano, e a regressão logística supera k-NN e gaussiano.
- **V1, precisão:** regressão logística e voto formam o melhor grupo (sem diferença entre si, $p = 0{,}18$) e superam os demais. **Cobertura:** o gaussiano é o melhor, sem diferença significativa para o voto ($p = 0{,}10$).
- **V2:** voto e Parzen não diferem entre si em nenhuma métrica ($p \geq 0{,}90$) e superam k-NN e gaussiano. Na F-measure, o voto também supera a regressão logística ($p = 0{,}005$). O gaussiano é significativamente o pior em todas as métricas.

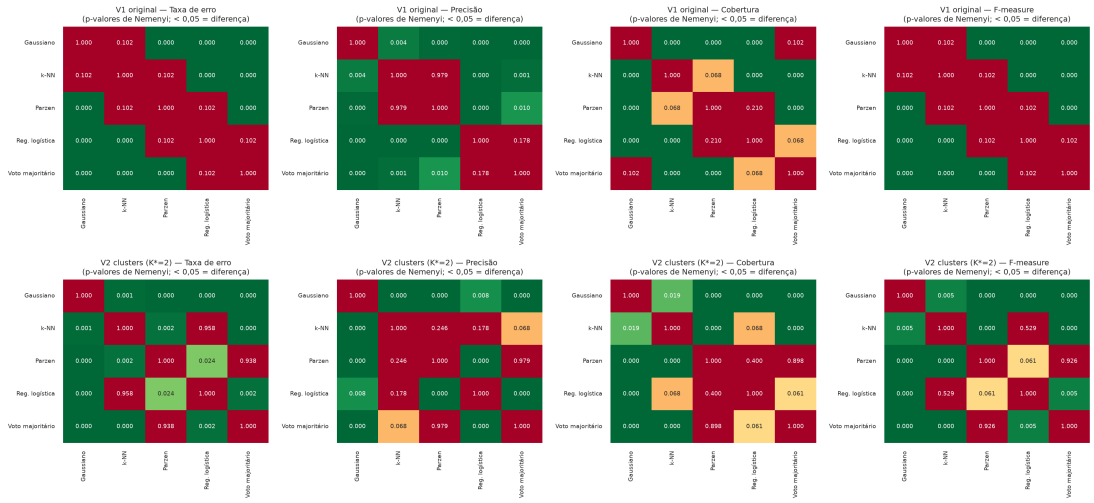


Figura 7. p-valores do pós-teste de Nemenyi (valores $< 0{,}05$ indicam diferença significativa).

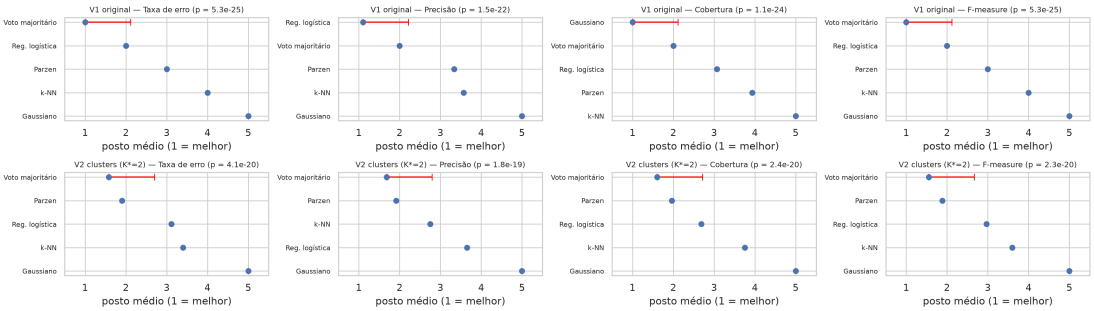


Figura 8. Postos médios dos classificadores; a barra vermelha indica a diferença crítica (CD).

(d) Curvas de aprendizagem. Para proporções de treinamento de 5% a 95% (passo de 5%), a base foi dividida em treino e teste por amostragem estratificada. Os classificadores usaram os hiper-parâmetros mais selecionados no item (a): na V1, City-Block com $k = 1$, $h = 0{,}50$ e $C = 10$; na V2, Euclidiana com $k = 1$, $h = 0{,}10$ e $C = 0{,}1$. Cada proporção foi repetida 5 vezes, e a Figura 9 mostra a F-measure média no treino e no teste.

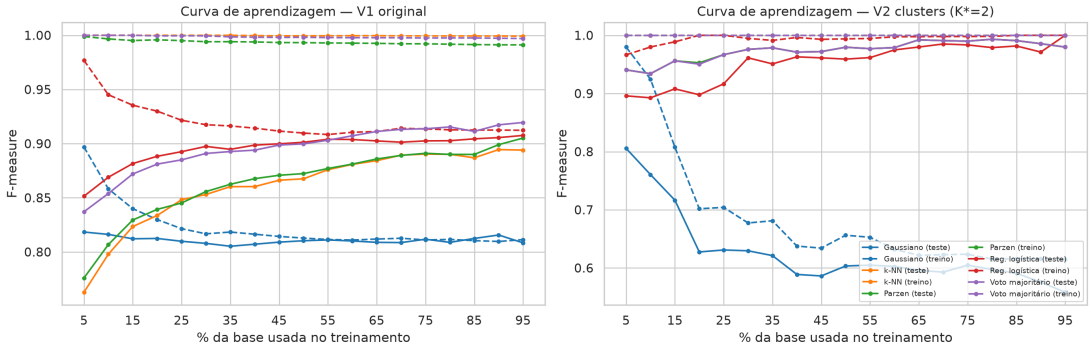


Figura 9. Curvas de aprendizagem da F-measure (linha cheia: teste; tracejada: treino).

- **V1:** k-NN e Parzen têm F-measure de treino próxima de 1, porque com $k = 1$ e h pequeno eles memorizam o treino. A F-measure de teste cresce com o tamanho do treino (de 0,76 para 0,89 no k-NN e de 0,78 para 0,91 no Parzen): são modelos de **alta variância**, que melhoram com mais dados. A regressão logística tem treino e teste próximos ($\approx 0{,}91$ a partir de 25%), ou seja, baixa variância. O gaussiano fica estável em $\approx 0{,}81$ no treino e no teste: **alto viés**, e mais dados não o melhoram. Com treino grande, o voto majoritário é o melhor no teste (0,920 com 95%).
- **V2:** k-NN, Parzen e voto têm curvas praticamente iguais (de 0,94 para 0,98). A regressão logística chega a 1,0 com 95% de treino. O gaussiano piora à medida que o treino cresce (de 0,81 para 0,56), coerente com a dificuldade de modelar a classe minoritária, muito pequena e dispersa, por uma normal multivariada.

Observações. Os intervalos de confiança são estreitos porque cada um vem da média de 30 repetições do 10-folds sobre a mesma base. Eles medem a variabilidade da divisão em folds, não a de amostrar novos conjuntos de dados. Na V2, o h de Parzen mais escolhido foi o menor valor da grade (0,1). Como o erro já é próximo de zero, isso não deve alterar as conclusões.

5. Resultados e Discussão

Esta seção reúne os principais resultados das duas questões, discute como eles se relacionam e aponta as limitações do estudo. Os números detalhados estão na Seção 4.

Tabela 10. Resumo dos principais resultados.

Item	Resultado
Escolha de K^* (Q1)	$(K, H) = (2, 2)$, silhueta 0,660; $K^* = 2$
Partição de K^* (Q1)	Grupos de 4567 e 34 e-mails; ARI $= -0{,}005$
Melhor classificador, V1	Voto majoritário: erro 6,55%, F-measure 0,917
Pior classificador, V1	Gaussiano: erro 17,67%, precisão 0,705
Melhor classificador, V2	Voto majoritário: erro 0,04%, F-measure macro 0,987
Testes estatísticos	Friedman rejeita H_0 em todos os casos ($p < 10^{-18}$); $CD = 1{,}114$
Tempo de execução	42,6 min no total (GPU A100 + 16 CPUs)

Síntese dos resultados.

Agrupamento e classes conhecidas. O resultado central da Questão 1 é que a melhor partição segundo a silhueta não tem relação com a classe spam/não-spam (ARI ≈ 0). O double k-means encontrou uma estrutura real: um grupo de 34 e-mails internos da HP Labs que usam com frequência muito alta um conjunto de 11 palavras (`hp`, `lab`, `telnet`, `650`, ...). Por ser pequeno, extremo e bem separado do resto, esse grupo produz uma silhueta alta. Três fatores explicam o resultado:

- **Sensibilidade a *outliers*:** a função objetivo é uma soma de erros quadráticos, então poucos e-mails com valores muito altos pesam bastante na partição;
- **Esparsidade e assimetria:** com 77% de zeros e caudas longas, a padronização z-score não deixa as variáveis com distribuições parecidas e amplia os valores extremos;
- **Critério de escolha:** a silhueta mede compacidade e separação, não concordância com classes externas. Uma partição com um grupo minúsculo e isolado pode ter silhueta alta.

Os outros pares (K, H) também tendem a isolar grupos pequenos (de 22 a 34 e-mails) ao lado de grupos grandes (Tabela 3). Isso mostra que a estrutura dominante da base, para esse algoritmo, não é a divisão spam $\times$ não-spam. O exercício ilustra uma lição importante: índices internos de validação não substituem a validação externa quando há classes conhecidas.

Desempenho dos classificadores. Na base original (V1), a ordem dos classificadores foi a mesma em todas as 30 repetições: voto majoritário, regressão logística, Parzen, k-NN e gaussiano. Os resultados mais relevantes:

- **O voto majoritário foi o melhor.** Combinar classificadores com vieses diferentes (um paramétrico linear, dois não paramétricos e um gaussiano) reduz os erros individuais. A diferença para a regressão logística (0,77 ponto percentual de erro) não foi significativa no Nemenyi, mas a vantagem sobre Parzen, k-NN e gaussiano foi.

- **A regressão logística foi o melhor classificador individual.** Ela é simples, tem baixa variância e alcançou a maior precisão (0,923), o que é desejável em filtros de spam, onde marcar um e-mail legítimo como spam custa caro.
- **Os métodos não paramétricos (k-NN e Parzen)** ficaram em posição intermediária. As curvas de aprendizagem indicam alta variância: eles melhoram à medida que o treino cresce e provavelmente se beneficiariam de mais dados ou de redução de dimensionalidade.
- **O bayesiano gaussiano foi o pior.** A hipótese de normalidade multivariada é inadequada para atributos esparsos, limitados em zero e de cauda longa. Ele classifica spam em excesso (cobertura de 0,950 com precisão de 0,705) e tem alto viés: o desempenho não melhora com mais dados.

Na versão com as classes vindas do agrupamento (V2), todos os classificadores, exceto o gaussiano, erram menos de 0,1%. A tarefa é fácil porque as classes foram definidas pelo próprio double k-means a partir de um grupo extremo em poucas variáveis. Assim, os resultados da V2 mostram principalmente que a partição da Questão 1 é bem separada no espaço dos atributos. Eles não indicam que esses classificadores sejam bons para detectar spam. O mau desempenho do gaussiano na V2 vem do desbalanceamento extremo (4567×34): estimar uma covariância 57×57 com cerca de 31 exemplos é mal condicionado, mesmo com regularização.

Validade dos experimentos. O protocolo foi desenhado para que a avaliação e a comparação sejam justas:

- os hiper-parâmetros foram escolhidos só com os dados de aprendizagem (5-fold interno), e o fold de teste nunca participou do ajuste nem da padronização;
- os 5 classificadores usaram exatamente as mesmas partições, o que permite testes pareados (Friedman e Nemenyi);
- a amostragem estratificada preservou a proporção das classes em todas as divisões.

Limitações.

- **Independência:** as 30 repetições usam a mesma base, então os intervalos de confiança medem a variabilidade da divisão em folds, não a de novas amostras de e-mails. Por isso são estreitos e devem ser lidos com cautela.
- **Grades de hiper-parâmetros:** na V2, o h de Parzen mais escolhido foi o menor da grade (0,1). Uma grade com valores menores poderia mudar ligeiramente o resultado, embora o erro já esteja próximo de zero.
- **Pré-processamento:** usamos apenas a padronização z-score. Uma transformação como $\log(1 + x)$, que reduz a assimetria, poderia beneficiar tanto o double k-means quanto o bayesiano gaussiano.

- **Registros duplicados:** as 391 linhas repetidas foram mantidas; elas podem cair ao mesmo tempo no treino e no teste e favorecer levemente o k-NN com $k = 1$.

Aspectos computacionais. O double k-means foi implementado em PyTorch com as 100 inicializações executadas em lote na GPU, o que levou cerca de 1 s por par (K, H). O k-NN, a janela de Parzen e o bayesiano gaussiano também rodaram na GPU. O experimento completo (Questões 1 e 2) levou 42,6 minutos, a maior parte na validação cruzada com ajuste interno da regressão logística, executada em paralelo em 16 CPUs. Isso tornou viável o protocolo de 600 folds externos (300 por versão da base), cada um com validação interna de 5 folds.